

高源邹

数据科学家｜2027 届

+86 182-0626-8132 ｜ 微信：Cassie__Gem ｜ yg2630@nyu.edu ｜ github.com/yuanzou0

个人概述：纽约大学数据科学硕士在读，聚焦离线评测、混合检索与 Agent 实验，能够从数据口径、实验设计和失败分析形成可审计结论。

教育经历

纽约大学（New York University）｜数据科学 硕士｜GPA 3.50/4.0 2025.09–2027.05

纽约大学（New York University）｜数学与数据科学 本科｜GPA 3.71/4.0 2023.01–2025.05

曼荷莲女子学院（Mount Holyoke College）｜转学｜数学与经济｜GPA 4.0/4.0 2021.08–2022.12

精选课程：机器学习、大数据、概率与统计、数据科学高级 Python、因果推断、数据管理与分析

实习经历

上海微创医疗科技有限公司｜数据分析实习生 2024.06–2024.08

- 将区域市场机会拆解为**医院渗透率**、**目标科室匹配**及**产品/地区分层**口径，建立供业务团队筛选潜在客户与区域机会的分析框架。
- 清洗并校验 **4,009 家医院**数据，按医院—科室关系识别 **262,644 条目标科室匹配记录**；交付包含渗透率、产品和地区字段的 **Excel 分析表**，供业务团队判断潜在客户与市场机会。

昆山杜克大学｜研究实习生 2023.07–2023.08

- 使用 **Python、R** 处理并整合 **10GB+** 研究数据，建立缺失值、字段格式、取值范围及跨表**一致性校验规则**，形成可用于后续统计分析的标准化数据集。
- 使用 **SQL** 完成查询、聚合与转换，并将 **30 余项**行业调研资料结构化整理，为研究团队的数据分析与结果解释提供**可追溯输入**。

项目经历

MovieLens 1M 推荐系统｜课程项目重构 GitHub 2026.04–2026.05

- 基于 **1,000,209 条交互**构建**无数据泄漏**的离线评测管线，采用全局时间顺序 **70/10/20** 切分及每用户 **100 个未交互负样本**，评估 RMSE/MAE 与 Precision/Recall/NDCG/Hit Rate@10。
- 在 **1,762 位用户**的 **288,460 个候选项**上，流行度基线的 NDCG@10/Recall@10 高于 SVD（**0.664/0.215 vs 0.580/0.188**）；SVD 将目录覆盖率由 **14.2%** 提升至 **48.8%**、新颖度提升 **8.0%**，揭示**准确性—覆盖率权衡**。

ContextOps Lab（个人项目）｜Agent 实验与可靠性分析 GitHub 2026.07–至今

- 设计覆盖 **7 类工作负载、36 种场景**的 Agent 配对实验，以任务成功、模型调用成本和端到端延迟评估上下文压缩策略。
- 4 组 32K/5-turn 真实模型实验中，成本下降 **89.9%**，但任务代理指标由 **4/4 降至 0/4**、中位延迟升高 **15.9 倍**；据此停止扩展并定位跨 query 缓存复用风险。

Primrose｜NYU Capstone · Genmab-Sponsored POC｜EMA 监管先例混合检索 2026.09–至今

- 参与构建 **225 个产品、2,678 份文档**的可审计 manifest；在 12 个产品、125 份 PDF 的 pilot 中形成 **6,505 个 citation-ready chunks**。
- 协作实现 **section-aware chunking、BGE、BM25 与 RRF 融合检索**；正式 Recall/MRR/nDCG 与引用评测待完成，不以数据规模代替质量结论。

技能与其他

编程与数据：Python（pandas、NumPy、scikit-learn、SciPy）、SQL、R、Excel、Git、GitHub Actions；**分析方法：**EDA、实验设计、统计推断、因果推断、置信区间、用户分群、推荐系统、AI 评测

语言与荣誉：TOEFL 108；NYU Dean's List（2024–2025）；Mildred L. Sanderson 数学奖（2022）